Disciplina Compiladores - UFS
Turma T01 2018.2
Profa. Beatriz T. Andrade

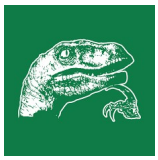

Especificação da Linguagem Tesauro

Introdução

Para variar um pouco, vamos criar uma linguagem cujas expressões e palavras reservadas são levemente diferentes das que costumamos usar na maioria das linguagens de programação. A linguagem **Tesauro** é uma linguagem imperativa, e apresenta as características descritas neste documento.

Tesauro é uma linguagem experimental, então esta especificação é passível de adaptações. Em caso de modificações na especificação, estas serão notificadas via SIGAA.

1. Características e léxico

Regras para identificadores:

- Pode-se utilizar: letras maiúsculas, letras minúsculas e underline ('_').
- O primeiro caractere deve ser sempre uma letra.
- Não são permitidos números, espaços em branco e caracteres especiais (ex.: @, $, +, -, ^, % etc.).
- Identificadores não podem ser iguais às palavras reservadas ou operadores da linguagem.
- Podem representar o nome do código, variáveis ou constantes (**`unalterable`**).

Tipos primitivos:

- A linguagem aceita os tipos symbol, real, integer.
- symbol: tipo que representa um elemento da tabela ASCII, sendo escrito com aspas simples. Exemplo: 'a', '\n'.
- real: números reais, com parte decimal separada por um ponto.
- integer: números inteiros. Podem ser expressos no sistema binário e decimal. Exemplo: b10100 (binário) ou d10 (decimal). Na base decimal não é necessário prefixo (mas ele é opcional).
- Identificadores que representam constantes com tipos primitivos (com modificador **`unalterable`**) só podem ser inicializados uma vez. A inicialização durante a definição é opcional. Caso seja feita posteriormente, deve ser usado o operador “=”.

Vetores:

- Um vetor é composto de uma ou mais variáveis com o mesmo tipo primitivo.
- Vetores com modificador **`unalterable`** devem ser inicializados em uma linha posterior à sua declaração. Neste caso, deve ser usado o operador “=”.
- O tamanho dos vetores é definido durante sua criação.
- Os índices dos vetores vão de 1 ao seu tamanho.
- Existem vetores multidimensionais. Exemplo: **`integer vector [2][3] nome;`**
- Vetores unidimensionais do tipo **`symbol`** podem ter seus valores definidos por cadeias entre aspas duplas (“ e ”).

Blocos

- Delimitados pelas palavras **`start`** e **`finish`**.

Comentários:

- A linguagem aceita comentários de uma ou mais linhas, delimitados por { e }.
- O funcionamento dos comentários de bloco em Tesauro são similares aos da linguagem C. Exemplo: o que acontece se você compilar /**/*/ em C? Estudem como um compilador C reconhece o fim de um comentário de bloco.

Estruturas de controle (mais detalhes na Seção Semântico):

- **`in case that`**
- **`as long as`**
- **`considering`**

Operadores:

- Possui operadores aritméticos, relacionais e booleanos.
- Comandos são terminados com ‘;’ (ponto-e-vírgula).

Funções primitivas:

- A linguagem possui dois procedimentos primitivos: **`capture`** e **`show`**

2. Sintático

A gramática da linguagem foi escrita em uma versão de E-BNF seguindo as seguintes convenções:

- Variáveis da gramática são escritas em letras minúsculas sem aspas;
- Tokens são escritos entre aspas simples;
- Símbolos escritos em letras maiúsculas representam o lexema de um token do tipo especificado;
- O símbolo | indica produções diferentes de uma mesma variável;
- O operador [ ] indica uma estrutura sintática opcional;
- O operador { } indica uma estrutura sintática que é repetida zero ou mais vezes.

```
programa : 'code' ID bloco

bloco : 'start' { declaracao } { comando } 'finish'

declaracao : tipo {ID ','} ID ';'
| 'unalterable' tipo ID [ '=' valor ] ';'

tipo-base : 'integer' | 'real' | 'symbol'

tipo : tipo-base | tipo-base 'vector' '[' exp ']' {'[' exp ']'}

var : ID | ID '[' N_INT ']' {'[' N_INT ']'}
unalt : ID | ID '[' N_INT ']' {'[' N_INT ']'}

valor : SYM | N_INT | N_REAL | STRING

comando :
  var ':=' exp ';'
  unalt '=' exp ';'
| 'capture' '(' {var ','} var ')' ';'
| 'show' '(' {exp ','} exp ')' ';'
| 'in' 'case' 'that' '(' exp-logica ')' 'do' comando ['else' comando]
| 'as' 'long' 'as' '(' exp-logica ')' 'do' comando
| 'in' 'case' 'that' '(' exp ')' 'do' comando ['else' comando]
| 'as' 'long' 'as' '(' exp ')' 'do' comando
| 'considering' var 'from' exp 'to' exp 'by' exp 'do' comando
| bloco

exp :
| valor
| var
| '(' exp ')'
| '-' exp
| exp '+' exp
| exp '-' exp
| exp '*' exp
| exp '/' exp
| exp '%' exp
| exp '==' exp
| exp '!=' exp
| exp '<=' exp
| exp '>=' exp
| exp '<' exp
| exp '>' exp
| '!' exp-logica
| exp-logica 'and' exp-logica
| exp-logica 'or' exp-logica
| exp-logica 'xor' exp-logica
| '!' exp
```

```
| exp 'and' exp
| exp 'or' exp
| expr 'xor' expr
```

3. Semântico:

- Nos casos omissos neste documento, a semântica da linguagem segue a semântica de C.
- A execução de um programa consiste na execução do código iniciado com a palavra **`code`**, seguida por um bloco.

Blocos

- Escopo das variáveis e constantes: global e local.

Estruturas de controle:

- **`in case that:`** similar ao “if-else” do C.
- **`as long as:`** similar ao “while” do C.
- **`considering`**: similar ao “for” do C. As expressões devem ter tipo integer ou symbol. A terceira expressão representa o incremento (passo) que a variavel sofrerá a cada iteração.

Operadores**:**

- Em operações entre os tipos inteiro e real, os valores inteiros devem ser convertidos para reais.
- A semântica das operações com resultado booleano é igual à de C: 0 vale como falso e qualquer outro inteiro é verdadeiro.
- A prioridade dos operadores é igual à de C, e pode ser alterada com o uso de parênteses.
- Em qualquer expressão, um caractere tem seu valor automaticamente promovido para inteiro.

Procedimentos primitivos:

- **`capture:`** procedimento para entrada de dados a partir do teclado. Salva os valores lidos nas variáveis que foram passadas como argumentos.
- **`show:`** procedimento para exibição de um ou mais valores resultantes de expressões passadas como argumentos.

O que deve ser verificado na análise semântica:

- Se o nome do programa e entidades criadas pelo usuário (variáveis, vetores e constantes) são inseridos na tabela de símbolos - com os atributos necessários - quando são declarados;

- Se uma entidade foi declarada e está em um escopo válido no momento em que ela é utilizada (regras de escopo são iguais às de C);

- Se entidades foram definidas (inicializadas) quando isso se fizer necessário;

- Checar a compatibilidade dos tipos de dados envolvidos nos **comandos**, **expressões e atribuições**.

4. Desenvolvimento do Trabalho

Trabalhos devem ser desenvolvidos em trio, dupla ou individualmente. Foi aberto um fórum no SIGAA para a discussão sobre as etapas. Em caso de dúvida, verifique inicialmente no fórum se ela

já foi resolvida. Se ela persiste, consulte a professora.

4.1. Ferramentas

- Submissão das etapas do projeto via SIGAA. Será criada uma tarefa para cada etapa.
- Implementação com SableCC e Java.

4.2. Avaliação

- A avaliação será feita com base nas etapas entregues e em entrevistas feitas com os grupos.
- A aula que define o prazo de entrega de cada etapa está especificada no plano de curso da disciplina.

4.3. Etapas

Análise Léxica (valor: 2.5):

- Três códigos em Tesauro que, unidos, usem todos os recursos da linguagem.
- Analisador léxico em SableCC.
- Impressão dos lexemas e tokens reconhecidos ou impressão dos erros

Análise Sintática (valor: 2.5):

- Analisador sintático em SableCC
- Impressão da árvore sintática em caso de sucesso ou impressão dos erros

Sintaxe Abstrata (valor: 2.5):

- Analisador sintático abstrato em SableCC
- Impressão da árvore sintática

Análise Semântica (valor: 2.5):

- Validação de escopo e de existência de identificadores
- Verificação de tipos

Geração de código (extra: 2.5):

- Código em linguagem alvo: Pascal

A critério da docente o valor das etapas pode ser modificado, desde que este novo cálculo produza uma nota não menor que a produzida pelo cálculo original. Entregas após o prazo sofrem penalidade de meio ponto por dia de atraso.

Bom trabalho!